

#### Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

# «Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Робототехники и комплексной автоматизации

КАФЕДРА Системы автоматизированного проектирования (РК-6)

# ОТЧЕТ О ВЫПОЛНЕНИИ ЛАБОРАТОРНОЙ РАБОТЫ

по дисциплине:

## Введение в искусственный интеллект

	_		
Абидоков Рашид Ширамбиевич			
PK6-11M			
1-2			
Программирование искусственного нейр			
	<u> Абидоков Р. Ш.</u>		
подпись, дата	<b>Абидоков Р. Ш.</b> фамилия, и.о.		
подпись, дата			
	PK6-11M 1-2		

## Оглавление

Задание на лабораторную работу	. 3
Описание входных данных	3
Описание используемой модели	.4
Описание программной реализации	5
Результаты обучения	. 6

### Задание на лабораторную работу

**Цель лабораторной работы** — создание программы, реализующей искусственный нейрон; разработка процедуры обучения нейрона; использование полученных результатов для решения тестовой задачи классификации

Тип нейрона – персептрон

Вариант обучающих данных на Рис.1

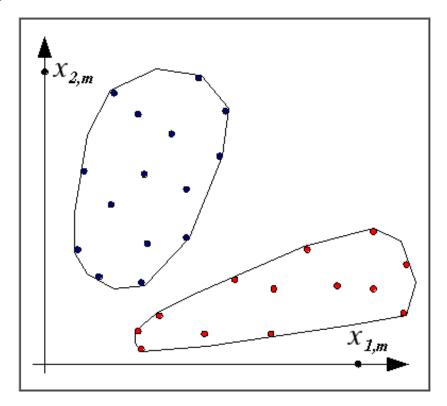


Рис 1.

#### Описание входных данных

Были взяты точки, распределенные на плоскости в соответствии с Рис. 1. Координаты точек и их класс приведены в таблице ниже. Из них был сформирован входной файл points.txt

Табл. 1

i	$x_i$	$y_i$	класс
1	7	2	0
2	3	10	1
3	12	3	0

4	6	5	1
5	14	0	0
6	6	9	1
7	17	-2	0
8	8	13	1
9	16	10	1

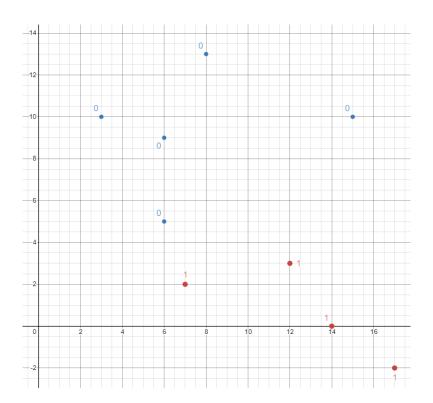


Рис 2. Принятое распределение точек

## Описание используемой модели

Перцептрон – это нейрон со ступенчатой функцией активации, т.е.

$$y_i = f(u_i) = \begin{cases} 1, & u_i \ge 0 \\ 0, & u_i < 0 \end{cases}$$

Где  $u_i = \sum_{j=1}^m w_j x_{ij}$  — взвешенная сумма входных сигналов, i — номер объекта обучающей выборки, j — номер параметра, m — количество параметров

Обучение нейрона сводится к подбору весов  $w_j$  путем минимизации среднеквадратичной ошибки на обучающей выборке

$$Q = \frac{1}{2} \sum_{i=1}^{n} (y_i - d_i)^2$$

Где n — количество объектов обучающей выборки,  $d_i$  — класс i-го объекта

В силу дискретности функции активации и, как следствие, невозможности брать производные функции ошибки, невозможно использование методов оптимизации выше нулевого порядка, таких как, например, градиентные методы.

#### Поэтому обучение производилось с помощью правила персептрона:

- 1. Выбираются начальные значения весов  $w_i = w_{i0}$
- 2. Для каждой обучающей пары  $(x_{i1}, x_{i2}), d_i$  выполняется ряд циклов уточнений входных весов:

Вычисляется  $y_i$ 

Если 
$$(d_i - y_i) = 1$$
, то  $w_i(t+1) = w_i(t) + \eta x_{ij}$ 

Если 
$$(d_i - y_i) = -1$$
, то  $w_i(t+1) = w_i(t) - \eta x_{ij}$ 

Если  $(d_i - y_i) = 0$  или  $t = t_{max}$ , то цикл прекращается

3. Повторяем циклические проходы по обучающей выборке до тех пор, пока решение не сойдется либо пока не будет превышено максимальное количество итераций

#### Описание программной реализации

Программная реализация выполнена на языке C++ с использованием компилятора gcc. Считываются координаты и классы точек из входного txt-файла, задается начальное приближение весов, нейрон обучается по алгоритму, описанному выше, после чего выводятся веса после обучения и метки классов  $d_i$  и  $y_i$ 

```
unsigned perceptron::fit_one(const std::vector<std::vector<double> >& X train,
                             const std::vector<bool>& y_train, size_t idx, unsigned max_iter) {
 double y_true = y_train[idx];
 while (count < max_iter) {</pre>
   double y_pred = this->out(X_train[idx]);
   if (y_true == y_pred) {
     break;
   weights_[0] += f_coeff * (y_true - y_pred);
    for (size_t i = 1; i < N_inputs_; i++) {</pre>
     weights_[i] += f_coeff * (y_true - y_pred) * X_train[idx][i - 1];
unsigned perceptron::fit(const std::vector<std::vector<double> >& X_train,
                         const std::vector<bool>& y train, unsigned max iter) {
 unsigned total count = 0;
  for (unsigned iter = 0; iter < max_iter; iter++) {</pre>
    for (size_t i = 0; i < X_train.size(); i++) {</pre>
      total_count += this->fit_one(X_train, y_train, i, 10);
  return total count;
```

## Результаты обучения

Обучение производилось с двумя различными начальными значениями весов. В первом случае все веса принимались нулевыми – при таком начальном приближении решение сошлось за два шага

Листинг 2. Вывод программы при нулевом начальном приближении

```
C:\Study\Introduction-to-AI\lab3>bin\main.out
weights0:
w0 : 0
w1 : 0
w2 : 0
weights after fit:
w0 : 0
w1 : -2
w2 : 4
n_iters: 2
p0: y_true0|
p1: y_true1|
p2: y_true0|
p3: y_true1|
p4: y_true0|
                    y_pred0
                    y_pred1
                    y_pred0
      y_true1
                       pred0
pred1
      y_true0
      y_true1
y_true1
                    y_pred1
```

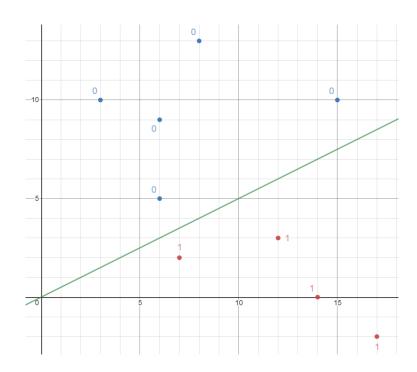


Рис 3. Прямая, соответствующая полученным весам

Табл. 2

N шага	0	1	2
$w_0$	0	-0.5	0
$w_1$	0	-3.5	-2
$w_2$	0	1	4

Во втором случае в качестве начальных весов были приняты значения (-60, -9.5, -3) — при таких весах разделяющая прямая выглядит так, как показано на Рис. 4. Т.е. приближение можно считать плохим

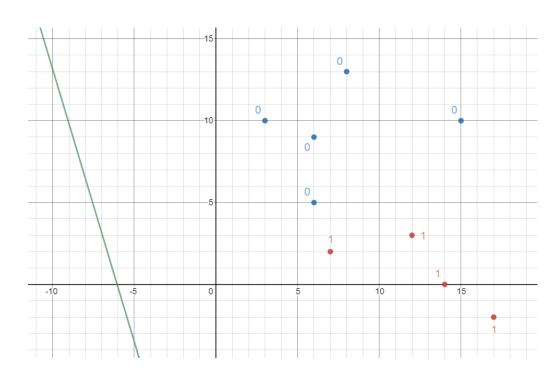


Рис 4. Прямая, соответствующая "плохому" нач. приближению

В этом случае решение сошлось за 4 итерации

Листинг 3. Вывод программы при плохом начальном приближении

N шага	0	1	2	3	4
$w_0$	-60	-59.5	-59	-58.5	-58
$w_1$	-9.5	-8	-6.5	-5	-2
$w_2$	-3	2	7	12	14.5

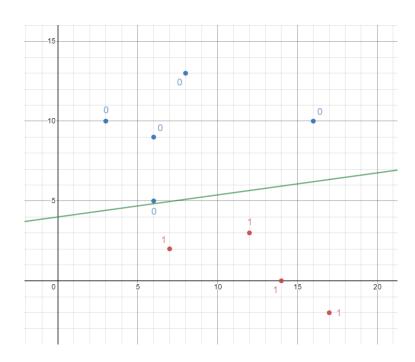


Рис 5. Прямая, соответствующая полученным весам